

Time Series Analysis

Lollins

2023 年 12 月 9 日

前言

时间序列分析的笔记，图像大多用 Python 完成，源代码放在 code 文件夹下。

Lollins

2023 年 12 月 9 日

目录

第一章 时间序列分析简介	1
1.1 时间序列的定义	1
1.1.1 随机过程中的一些基本定义	1
1.1.2 随机序列定义	2
1.2 时间序列分析方法	3
1.2.1 描述性时间序列分析	3
1.2.2 统计时间序列分析	3
1.3 时间序列分析软件	3
第二章 时间序列的预处理	4
2.1 平稳序列的定义	4
2.1.1 特征统计量	4
2.1.2 平稳时间序列的定义	5
2.1.3 平稳时间序列的统计性质	7
2.1.4 平稳性的重大意义	9
2.2 序列的平稳性检验	9
2.2.1 时序图检验	9
2.2.2 自相关图检验	10
2.3 纯随机性检验	14
2.3.1 纯随机序列的定义	14

目录	II
2.3.2 纯随机序列的性质	15
2.3.3 纯随机性检验	16
2.3.4 Eviews 差分指令	17
第三章 ARMA 模型的性质	18
3.1 Wold 分解定理	18
3.1.1 Wold 分解定理的内容	18
3.2 AR 模型	19
3.2.1 差分的定义	19
3.2.2 AR 模型的定义	20
3.2.3 AR 模型的平稳性判别	20
3.2.4 平稳 AR(p) 模型性质	21
3.3 MA 模型	26
3.3.1 MA 模型的定义	26
3.3.2 MA 模型的统计性质	27
3.3.3 MA(q) 模型的可逆性	28
3.3.4 MA 模型偏自相关系数拖尾	29
3.4 ARMA 模型	30
3.4.1 ARMA 模型的定义	30
3.4.2 平稳条件与可逆条件	30
3.4.3 传递形式与逆转形式	31
3.4.4 ARMA(p,q) 模型的统计性质	31
3.4.5 ARMA 模型的相关性	32
第四章 平稳序列拟合与预测	33
4.1 建模步骤	33
4.2 单位根检验	33
4.2.1 DF 检验	33

目录	III
----	-----

4.2.2	DF 检验的等价表达	34
4.2.3	DF 检验的三种类型	34
4.2.4	ADF 检验	35
4.2.5	纯随机性检验	36
4.3	模型识别	36
4.4	参数估计	36
4.4.1	矩估计	37
4.4.2	极大似然估计	38
4.4.3	最小二乘估计	38
4.5	模型检验	38
4.5.1	模型的显著性检验	38
4.5.2	参数的显著性检验	39
4.6	模型优化	39
4.6.1	AIC 准则	39
4.6.2	BIC 准则	39
4.7	序列预测	40
4.7.1	线性预测函数	40
4.7.2	预测方差最小原则	40
4.7.3	线性最小方差预测的性质	41

第五章 无季节效应的非平稳序列分析 44

5.1	Crammer 分解定理	44
5.2	差分平稳	45
5.2.1	差分运算的实质	45
5.2.2	差分方式的选择	45
5.2.3	过差分	45
5.3	ARIMA 模型	46
5.3.1	模型结构	46

5.3.2	ARIMA 模型的平稳性	46
5.3.3	ARIMA 模型建模步骤	46
5.3.4	ARIMA 模型预测	47
5.3.5	预测值	48
5.4	疏系数模型	48
5.4.1	疏系数模型的类型	48

第一章 时间序列分析简介

1.1 时间序列的定义

1.1.1 随机过程中的一些基本定义

定义 1.1.1 (概率空间). $(\Omega, \mathcal{F}, \mathcal{P})$ 称为概率空间当且仅当其满足以下的条件:

1. Ω -Simple Space 样本空间, 试验中所有可能结果的集合。
2. \mathcal{F} -Sets of events 事件集合, 是 Ω 子集构成的集合, 即 $\mathcal{F} \subset 2^\Omega$ (Ω 的幂集), 并且它需要满足以下三个特征 (也就是必须是 σ -field):
 - $\Phi \subset \mathcal{F}$ (即必须包含不可能事件);
 - 如果 $A \subset \mathcal{F}$, 那么 $A^c \subset \mathcal{F}$;
 - 如果 $A_1, A_2, \dots, A_i \in \mathcal{F}$, 那么 $\bigcup_{i=1}^{\infty} A_i \in \mathcal{F}$.
3. \mathcal{P} -Probability measure 概率测度 (或概率), 描述一次随机试验中被包含在 \mathcal{F} 中的所有事件的可能性。并且它也类似的需要满足以下三个特征:
 - $0 \leq \mathcal{P}(A) \leq 1$, 即限制了总测度为 1;
 - $\mathcal{P}(\Omega) = 1$, 即包含样本空间且概率为 1;
 - 如果 A_1, A_2, \dots, A_i 为互斥事件, 那么 $\mathcal{P}(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} \mathcal{P}(A_i)$

定义 1.1.2 (随机过程). 随机过程是概率空间 $(\Omega, \mathcal{F}, \mathcal{P})$ 上的一族随机变量 $\{X(t), t \in T\}$, 其中 t 是参数, 它属于某个指标集 T , T 称为参数集。

注: 依据参数集 T 可分为**离散参数过程**和**连续参数过程**, 把**离散参数过程**称为**随机序列**。

1.1.2 随机序列定义

定义 1.1.3 (随机序列). 按时间顺序排列的一组随机变量

$$\dots, X_1, X_2, \dots, X_t, \dots$$

定义 1.1.4 (观察值序列). 随机序列的 n 个有效观察值, 称之为序列长度为 n 的观察值序列

$$x_1, x_2, \dots, x_n$$

随机序列与观察值序列的关系

- 观察值序列是随机序列的一个实现;
- 通过分析观察值序列的性质, 由观察值序列的性质来推断随机序列的性质.

随机序列的特点

- 随机序列中数据的位置与实践有关;
- 时间序列是对相关指标变量在不同时间进行观察所得到的结果。是一个观察结果, 一个实现;
- 时间序列中的数据可以是一个时期内的数据也可以是一个时点上的数据。流量与存量;
- 时间序列通常存在前后时间上的相依性.

时间序列的分类

- 按所研究对象的维度，有一元时间序列和多元时间序列；
- 按观察时间的连续与否可将时间序列分为离散时间序列和连续时间序列；
- 按时间序列的统计特征分，有平稳时间序列和非平稳时间序列两类。

时间序列分析的目的

时间序列分析所讨论的内容，就是对观察到的时间序列数据进行研究，分析时间序列的统计特征和依存关系，找出系统的内在发展规律，建立起能反映变量变化的动态模型，并将这种动态模型用于预测等应用领域。

1.2 时间序列分析方法

1.2.1 描述性时间序列分析

1.2.2 统计时间序列分析

$$\left\{ \begin{array}{l} \text{频域分析方法} \\ \text{时域分析方法} \end{array} \right.$$

1.3 时间序列分析软件

Matlab, Eviews, R 和 SAS 等。

第二章 时间序列的预处理

2.1 平稳序列的定义

2.1.1 特征统计量

一、概率分布

概率分布的意义

随机变量族的统计特征完全由它们的联合分布函数或联合密度函数决定。

定义 2.1.1 (时间序列概率分布族). 对于时间序列 $\{X_t, t \in T\}$, 任取正整数 m , 任取 $t_1, t_2, \dots, t_m \in T$, 则 m 维随机向量 $(X_1, X_2, \dots, X_m)'$ 的联合概率分布记为 $F_{t_1, t_2, \dots, t_m}(x_1, x_2, \dots, x_m)$, 由这些有限维分布函数构成的全体

$$\{F_{t_1, t_2, \dots, t_m}(x_1, x_2, \dots, x_m), \forall m \in N, \forall t_1, t_2, \dots, t_m \in T\} \quad (2.1)$$

就称为序列 $\{X_t\}$ 的概率分布族。

注：默认 t 为正整数。

实际应用的局限性

在实际应用中, 要得到序列的联合概率分布几乎是不可能的, 而且联合概率分布通常涉及非常复杂的数学运算, 这些原因导致我们很少直接使用联合概率分布进行时间序列分析。

二、特征统计量

- 均值: $\mu_t = EX_t = \int_{-\infty}^{\infty} x dF_t(x)$
- 方差: $DX_t = E(X_t - \mu_t)^2 = \int_{-\infty}^{\infty} (x - \mu_t)^2 dF_t(x)$
- 自协方差: $\gamma(t, s) = E(X_t - \mu_t)(X_s - \mu_s)$
- 自相关系数: $\rho(t, s) = \frac{\gamma(t, s)}{\sqrt{DX_t \cdot DX_s}}$

注: $\gamma(s, t) = \gamma(t, s)$, $|\rho(t, s)| \leq 1$

2.1.2 平稳时间序列的定义

一、严平稳

严平稳是一种条件比较苛刻的平稳性定义, 它认为只有当序列所有的统计性质都不会随着时间的推移而发生变化时, 该序列才能被认为平稳。

定义 2.1.2 (严平稳). 设 $\{X_t\}$ 为一时间序列, 对 \forall 正整数 $m, \forall t_1, t_2, \dots, t_m \in T, \forall$ 正整数 τ , 有

$$F_{t_1, t_2, \dots, t_m}(x_1, x_2, \dots, x_m) = F_{t_1+\tau, t_2+\tau, \dots, t_m+\tau}(x_1, x_2, \dots, x_m) \quad (2.2)$$

则称时间序列 $\{X_t\}$ 为严平稳时间序列。

二、宽平稳

宽平稳是使用序列的特征统计量来定义的一种平稳性。它认为序列的统计性质主要由它的低阶矩决定, 所以只要保证序列低阶矩平稳 (二阶), 就能保证序列的主要性质近似稳定。

定义 2.1.3 (宽平稳). 设 $\{X_t\}$ 为一时间序列, 若满足以下条件

1. $EX_t^2 < \infty, \forall t \in T$

$$2. EX_t = \mu, \mu \text{ 为常数}, \forall t \in T$$

$$3. \gamma(t, s) = \gamma(k, k + s - t), \quad \forall t, s, k \text{ 且 } k + s - t \in T$$

则称时间序列 $\{X_t\}$ 为宽平稳时间序列。

三、严平稳与宽平稳的关系

$$\left\{ \begin{array}{l} \text{严平稳} \not\Rightarrow \text{宽平稳} \\ \text{严平稳} \not\Leftarrow \text{宽平稳} \\ \text{严平稳} + \text{二阶矩存在} \Rightarrow \text{宽平稳} \\ \text{在正态分布假设下, (严平稳} \Leftrightarrow \text{宽平稳)} \end{array} \right.$$

注：以后见到的平稳时间序列，如果没有特别注明，都是**宽平稳时间序列**。如果序列不满足平稳条件，就称为**非平稳时间序列**。

例 2.1.4 (白噪声序列 (White Noise)). 一个简单的随机时间序列是一具有零均值同方差的独立分布序列： $X_t = \mu_t, \mu_t \sim N(0, \sigma^2)$ 。

解. 由于 X_t 具有相同的均值和方差，且协方差等于 0，有定义可以得到**白噪声序列是平稳的** □

例 2.1.5 (随机游走序列 (Random Walk)). 该随机时间序列是由随机过程 $X_t = X_{t-1} + \mu_t$ 生成，其中 μ_t 是一个白噪声序列。

解. 由 $\mu_t \sim N(0, \sigma^2)$ ，我们可以知道该序列的均值满足

$$E(X_t) = E(X_{t-1}) + E(\mu_t) = E(X_{t-1})$$

我们设序列 X_t 的初值为常数 X_0 , 则

$$\begin{aligned} X_1 &= X_0 + \mu_1 \\ X_2 &= X_1 + \mu_2 = X_0 + \mu_1 + \mu_2 \\ &\dots = \dots \\ X_t &= X_0 + \sum_{i=1}^t \mu_i \end{aligned}$$

由于 X_0 为常数, μ_t 为一个白噪声, 所以 $Var(X_t) = t\sigma^2$

即 X_t 的方差和时间有关而非常数, 它是一个**非平稳序列**. □

2.1.3 平稳时间序列的统计性质

一、常数均值

$$EX_t = \mu, \forall t \in T \quad (2.3)$$

二、自协方差函数和自相关系数只依赖于时间的平移长度而与时间的起止点无关

- 延迟 k 自协方差函数

$$\gamma(k) = \gamma(t, t+k), \forall k \text{ 为整数} \quad (2.4)$$

- 延迟 k 自相关系数

$$\rho_k = \frac{\gamma(k)}{\gamma(0)} \quad (2.5)$$

由式2.5, 我们可以得到**自相关系数**的如下性质:

- **规范性:** $\rho_0 = 1$, 且 $|\rho_k| \leq 1, \forall k$;
- **对称性:** $\rho_k = \rho_{-k}$;

• **非负定性:** $\Gamma_m = \begin{pmatrix} \rho_0 & \rho_1 & \cdots & \rho_{m-1} \\ \rho_1 & \rho_0 & \cdots & \rho_{m-2} \\ \vdots & \vdots & \cdots & \vdots \\ \rho_{m-1} & \rho_{m-2} & \cdots & \rho_0 \end{pmatrix}$, Γ_m 为非负定自协方差系数阵;

• **非唯一性:** 一个平稳时间序列一定唯一决定了它的自相关系数, 但一个自相关系数未必唯一对应着一个平稳时间序列.

例 2.1.6 (平稳序列的线性变换). 平稳序列 $\{X_t\}$, 期望 μ , 自协方差函数 $\gamma(t)$, 经线性变化后, 还是平稳序列.

证明. 令 $Y_t = a + bX_t$, 则 $EY_t = a + b\mu$, $\text{Cov}(Y_s, Y_{s+t}) = b^2 \text{Cov}(X_s, X_{s+t}) = b^2 \gamma(t)$, 可见 $\{Y_t\}$ 平稳. 若取

$$Y_t = \frac{X_t - \mu}{\sqrt{\gamma_0}}$$

则 $EY_t = 0$, $\text{Var}(Y_t) = 1$, 称 $\{Y_t\}$ 为 $\{X_t\}$ 的标准化序列. \square

例 2.1.7 (调和平稳序列). 设 a, b 为常数, 随机变量 U 在 $(-\pi, \pi)$ 内均匀分布, 则

$$X_t = b \cos(at + U), t \in \mathbb{Z}$$

是平稳序列, 称为调和平稳序列.

证明.

$$\begin{aligned} EX_t &= \frac{1}{2\pi} \int_{-\pi}^{\pi} b \cos(at + u) du = 0, \\ E(X_t X_s) &= \frac{1}{2\pi} \int_{-\pi}^{\pi} b^2 \cos(at + u) \cos(as + u) du \\ &= \frac{1}{2} b^2 \cos((t - s)a), \end{aligned}$$

证毕! \square

2.1.4 平稳性的重大意义

- 在平稳序列场合，序列的均值等于常数，这意味着原本含有可列多个随机变量的均值序列变成了只含有一个变量的常数序列。

$$\{\mu_t, t \in T\} \Rightarrow \{\mu, t \in T\} \quad (2.6)$$

- 原本每个随机变量的均值（方差，自相关系数）只能依靠唯一的一个样本观察值去估计，现在由于平稳性，每一个统计量都将拥有大量的样本观察值。
- 这极大地减少了随机变量的个数，并增加了待估变量的样本容量。极大地简化了时序分析的难度，同时也提高了对特征统计量的估计精度。

2.2 序列的平稳性检验

检验的方法分为图检验与构造检验统计量进行假设检验。

图检验分为时序图检验和自相关图检验。

2.2.1 时序图检验

得到观察值序列后，我们绘制该序列的时序图，根据时序图的不同特征，可以把序列分为三大类。

1、序列具有明显的趋势特征

如果序列具有明显的趋势特征，那么该序列显然不具有常数均值，所以趋势序列可以判断为非平稳。

例 2.2.1. 图 2.1 时序图显示：序列有明显的递增趋势特征，所以是非平稳序列。




图 2.1 1978-2012 年我国第三产业占国内生产总值

2、序列具有明显的周期特征

具有周期特征的序列平稳性识别是困难的。理论上，如果周期波动的振幅和频率不随着时间的变化而变化，通常序列是平稳的，例如例2.1.7中的调和平稳序列。但是如果 $X_t = b_t \cos(a_t t + U)$ ，振幅和频率随着时间的变化而变化，那么序列 $\{X_t\}$ 就是非平稳序列。

3、序列既没有趋势特征，也没有周期特征

如果一个序列既没有明显的趋势特征，也没有明显的周期特征，几乎是围绕着一个常数附近做有解波动，这通常是平稳序列。

2.2.2 自相关图检验

例 2.2.2. 利用图检验方法判断 1915-2004 年澳大利亚自杀率序列（每 10 万人自杀人口数）的平稳性，如图 2.2 所示。

图 2.2 难以把握该序列的平稳性，我们可以借助自相关图的性质来进一步辅助判别。

Python 中可以用 statsmodels 库来绘制自相关图，如图 2.3 所示。




图 2.2




图 2.3

自相关图是一个平面二维坐标悬垂线图，横坐标表示延迟时期数，纵坐标表示自相关系数，悬垂线的长度表示自相关系数的大小。

1、序列具有明显的趋势特征

该序列的时序图与自相关图如图2.4所示，自相关图呈现明显的倒三角特征，是非平稳序列，代码为 2_4.py。




图 2.4

2、序列具有明显的周期特征

该序列的时序图与自相关图如图2.5所示，自相关图呈现明显的周期特征，是非平稳序列，代码为 `2_5.py`。

对于有周期性的序列，平稳与非平稳时间序列的自相关图的图像很相像，但是平稳时间序列的自相关图随着之后 (lag) 的增加，自相关系数减小的更快。从图2.6中可以看出，代码为 `2_5a.py`。

3、平稳时间序列

平稳时间序列的自相关图，除了 0 阶延迟为 1，其余各阶自相关系数都很小，而且自相关系数时正时负，没有倒三角特征，也没有周期特征，如图2.7所示，代码为 `2_6.py`。




图 2.5




图 2.6 蓝色为平稳时间序列，绿色为非平稳




图 2.7

2.3 纯随机性检验

拿到一个观察值序列后，首先判断它的平稳性。通过**平稳性检验**，可以将序列分为**平稳**和**非平稳**。

对于平稳时间序列，我们有一套非常成熟的平稳序列建模方法。但是，并不是所有的平稳时间序列都值得建模。

如果序列值彼此之间没有任何相关性，那就意味着该序列是一个没有记忆的序列，过去的行为对将来的发展没有丝毫影响，这种序列称为**纯随机序列**。从统计分析的角度来说，纯随机序列是没有任何分析价值的序列。

2.3.1 纯随机序列的定义

定义 2.3.1 (白噪声 (White Noise) 序列). 如果对于时间序列 $\{X_t\}$ 满足以下性质：

- 1、 任取 $t \in T$ ，有 $E(X_t) = \mu$ ；

2、任取 $t \in T$, 有

$$\gamma(t, s) = \begin{cases} \sigma^2, t = s \\ 0, t \neq s \end{cases} \quad (2.7)$$

称序列 $\{X_t\}$ 为纯随机序列, 也称为白噪声 (*White Noise*) 序列, 简记为 $X_t \sim WN(\mu, \sigma^2)$ 。容易证明, 白噪声序列是平稳序列, 而且是最简单的平稳序列。

2.3.2 纯随机序列的性质

1、纯随机性

白噪声序列具有以下性质:

$$\gamma(k) = 0, \forall k \neq 0 \quad (2.8)$$

这说明白噪声序列之间没有任何相关联系, 这种“没有记忆”的序列就是**白噪声序列**。

如果序列值之间呈现出某种显著的相关分析:

$$\gamma(k) \neq 0, \exists k \neq 0 \quad (2.9)$$

说明**该序列不是纯随机序列**, 该序列间隔 k 期之间存在一定程度的相互影响。

2、方差齐性

所谓的方差齐性, 是指序列中每一个变量的方差都相等, 即

$$DX_t = \gamma(0) = \sigma^2 \quad (2.10)$$

如果序列不满足方差齐性, 就称该序列具有**异方差性质**。

2.3.3 纯随机性检验

如果一个序列是纯随机的，那么它的序列值之间应该没有任何相关关系，即式2.8所示。

Bartlett 证明，如果一个时间序列是纯随机的，得到一个观察期数为 n 的观察序列 $\{x_t, t = 1, 2, \dots, n\}$ ，那么该序列的延迟非零期的样本自相关系数将近服从均值为 0，方差为序列观察期倒数的正态分布，即

$$\hat{\rho}_k \overset{\bullet}{\sim} N(0, \frac{1}{n}), \forall k \neq 0 \quad (2.11)$$

式中， n 为序列观察期数。

根据 Bartlett 定理，我们可以构造检验统计量来检验序列的纯随机性。

1、假设条件

原假设：延迟期数小于或等于 m 期的序列值之间相互独立，即序列是延迟到 m 期都是平稳，纯随机的。

备择假设：延迟期数小于或等于 m 期的序列值之间有相关性。

该假设条件用数学语言描述为：

$$\begin{aligned} H_0 : \rho_1 = \rho_2 = \dots = \rho_m = 0, \forall m \geq 1 \\ H_1 : \text{至少存在某个 } \rho_k \neq 0, \forall m \geq 1, k \leq m \end{aligned} \quad (2.12)$$

2、检验统计量

(1)Q 统计量

Box 和 Pierce 推导出了 Q 统计量：

$$Q = n \sum_{k=1}^m \hat{\rho}_k^2 \overset{\bullet}{\sim} \chi^2(m) \quad (2.13)$$

n 为序列观察期数， m 为指定延迟期数。

(2)LB 统计量

实际应用中，人们发现 Q 统计量在大样本场合检验效果很好，但在小样本场合不太准确。为了弥补这一缺陷，Ljung 和 Box 又推导了 LB 统计量

$$LB = n(n+2) \sum_{k=1}^m \left(\frac{\hat{\rho}_k^2}{n-k} \right) \sim \chi^2(m) \quad (2.14)$$

以上 (1) 和 (2) 统计量的拒绝域都是 $Q > \chi^2(m)_{1-\alpha}$ 。

2.3.4 Eviews 差分指令

对序列 x_t 做差分，即

$$y_t = x_t - x_{t-1} \quad (2.15)$$

指令如下为 `genr y = D(x)`，同理，二阶差分为 `genr y = D(D(x))`。

第三章 ARMA 模型的性质

3.1 Wold 分解定理

3.1.1 Wold 分解定理的内容

定义 3.1.1 (Wold 分解定理). 对于任意一个离散平稳时间序列 $\{x_t\}$, 它都可以分解为两个不相关的平稳序列之和, 其中一个为确定性的 (*deterministic*), 另一个为随机性的 (*stochastic*), 不妨记作:

$$x_t = V_t + \xi_t \quad (3.1)$$

确定性序列 $\{V_t\}$ 代表序列的当期波动可以由其历史信息预测的部分。Wold 证明, 平稳时间序列的确定性部分一定可以表达为历史序列值的线性组合:

$$V_t = \sum_{j=1}^{\infty} \phi_j x_{t-j} \quad (3.2)$$

随机序列 $\{\xi_t\}$ 代表序列的当期波动不能由其历史信息预测的部分。Wold 证明, 这部分信息可以等价表达为:

$$\xi_t = \sum_{j=0}^{\infty} \theta_j \varepsilon_{t-j} \quad (3.3)$$

式中, $\theta_0 = 1, \sum_{j=0}^{\infty} \theta_j^2 < \infty$, $\{\varepsilon_t\}$ 称为新息过程 (innovation process), 是每个过程新加入的随机信息。 ε_t 为白噪声序列, 序列值之间相互独立, 不可预测, 通常假定 $\{\varepsilon_t\} \stackrel{i.i.d}{\sim} N(0, \sigma_\varepsilon^2)$

具有式3.2结构的模型是 1927 年 Yalu 提出的自回归 (autoregression) 模型, 简称 AR 模型。具有式3.3结构的模型是 1931 年 Walker 提出的移动平均 (moving average) 模型, 简称 MA 模型。

3.2 AR 模型

3.2.1 差分的定义

- 一阶差分: $\nabla x_t = x_t - x_{t-1}$
- p 阶差分: $\nabla^p x_t = \nabla^{p-1} x_t - \nabla^{p-1} x_{t-1}$
- k 步差分: $\nabla_k x_t = x_t - x_{t-k}$

定义 B 为一个延迟算子, 即 $B^p = x_{t-p}$, 则我们有

- 一阶差分: $\nabla x_t = (1 - B)x_t$
- p 阶差分: $\nabla^p x_t = (1 - B)^p x_t$
- k 步差分: $\nabla_k x_t = (1 - B^k)x_t$

差分算子有如下性质:

- 1、 $B^0 = 1$;
- 2、 常数的任意结束延迟仍然等于常数, 即 $B^p c = c$;
- 3、 对于任意常数, 有 $B^p(cx_t) = cx_{t-p}$
- 4、 对任意两个序列 $\{x_t\}, \{y_t\}$ 有 $B(x_t \pm y_t) = x_{t-1} \pm y_{t-1}$

关于差分方程的解法, 可以参考周义仓老师的《差分方程及其应用》第二章的内容。

3.2.2 AR 模型的定义

定义 3.2.1. 具有如下结构的模型称为 p 阶自回归模型，简记为 $AR(p)$:

$$\begin{cases} x_t = \phi_0 + \phi_1 x_{t-1} + \phi_2 x_{t-2} + \dots + \phi_p x_{t-p} + \varepsilon_t \\ \phi_p \neq 0 \\ E(\varepsilon_t) = 0, \text{Var}(\varepsilon_t) = \sigma_\varepsilon^2, E(\varepsilon_t \varepsilon_s) = 0, s \neq t \\ E(x_s \varepsilon_t) = 0, \forall s < t \end{cases} \quad (3.4)$$

$AR(p)$ 模型有三个限制条件:

- 1、 $\phi_p \neq 0$ 。保证模型的最高阶数为 p 。
- 2、 $E(\varepsilon_t) = 0, \text{Var}(\varepsilon_t) = \sigma_\varepsilon^2, E(\varepsilon_t \varepsilon_s) = 0, s \neq t$ 。保证随机干扰项 $\{\varepsilon_t\}$ 为零均值白噪声序列。
- 3、 $E(x_s \varepsilon_t) = 0, \forall s < t$ 。保证当期的随机干扰项与过去的序列值无关。

当 $\phi_0 = 0$ ，自回归模型又称为中性化 $AR(p)$ 模型。非中心化 $AR(p)$ 序列都可以通过下面的变换转化为中心化 $AR(p)$ 模型。令

$$\mu = \frac{\phi_0}{1 - \phi_1 - \dots - \phi_p}, y_t = x_t - \mu \quad (3.5)$$

则 $\{y_t\}$ 为 $\{x_t\}$ 的中心化序列。中心化序列就是将整个非中心化序列平移一个常数，这个整体的移动对序列值之间的相关关系没有任何影响。

引入了延迟算子，中心化 $AR(p)$ 模型又可以简记为

$$\Phi(B)x_t = \varepsilon_t \quad (3.6)$$

式中， $\Phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p$ ，称为 p 阶自回归系数多项式。

3.2.3 AR 模型的平稳性判别

并非所有的 AR 模型都是平稳的，图示法只是一种粗糙的直观判别方法，我们有两种准确的平稳性判断方法：特征根判别法和平稳域判别。

1、特征根判别法

任一中心化 AR(p) 模型 $\Phi(B) = \varepsilon_t$ 都可以视为一个非齐次线性差分方程

$$x_t - \phi_1 x_{t-1} - \phi_2 x_{t-2} - \dots - \phi_p x_{t-p} = \varepsilon_t \quad (3.7)$$

$\{x_t\}$ 平稳要求差分方程的特征根都在单位圆内, 即

$$|\lambda_i| < 1, \quad i = 1, 2, \dots, p \quad (3.8)$$

2、平稳域判别法

从参数向量 $(\phi_1, \phi_2, \dots, \phi_p)'$ 角度考虑, 从 p 维欧氏空间取一个子集, 满足:

$$\{\phi_1, \phi_2, \dots, \phi_p \mid \text{特征根都在单位圆内}\}$$

称为 AR(p) 模型的平稳域。

对于低阶 AR 模型, 用平稳域的方法判别模型的平稳性通常更为简便。

(1)AR(1) 模型的平稳域

AR(1) 模型为: $x_t = \phi_1 x_{t-1} + \varepsilon_t$, 根据特征根判别法, 可以求得 AR(1) 模型的平稳域为 $\{|\phi_1| < 1\}$

(2)AR(2) 模型的平稳域

AR(2) 模型为: $x_t = \phi_1 x_{t-1} + \phi_2 x_{t-2} + \varepsilon_t$, 根据特征根判别法, 可以求得 AR(2) 模型的平稳域为 $\{|\phi_2| < 1, \phi_2 \pm \phi_1 < 1\}$

3.2.4 平稳 AR(p) 模型性质

1、均值

对于 AR 模型满足方程3.4, 两边同时取期望

$$Ex_t = E(\phi_0 + \phi_1 x_{t-1} + \phi_2 x_{t-2} + \dots + \phi_p x_{t-p} + \varepsilon_t)$$

根据平稳时间序列的常数均值性质, 有 $Ex_t = \mu$ ($\forall t \in T$), 上式等价于

$$\begin{aligned} (1 - \phi_1 - \cdots - \phi_p)\mu &= \phi_0 \\ \Rightarrow \mu &= \frac{\phi_0}{1 - \phi_1 - \cdots - \phi_p} \end{aligned}$$

特别的, 对于中心化 AR(p) 模型, $Ex_t = 0$

2、方差

为求平稳 AR(p) 模型的方差, 需要借助 Green 函数的帮助。

定义 3.2.2 (Green 函数). 假设 $\{x_t\}$ 为任意阶数的平稳 AR 模型, 那么一定存在一个常数序列 $\{G_j\}(j = 0, 1, 2, \dots)$, 使得 $\{x_t\}$ 可以等价于纯随机序列 $\{\varepsilon_t\}$ 的线性组合, 即

$$\begin{aligned} x_t &= \phi_1 x_{t-1} + \phi_2 x_{t-2} + \cdots + \phi_p x_{t-p} + \varepsilon_t \\ &= G_0 \varepsilon_t + G_1 \varepsilon_{t-1} + G_2 \varepsilon_{t-2} \cdots \end{aligned} \quad (3.9)$$

这个常数序列 $\{G_j\}$ 就称为 Green 函数。

基于 Green 函数, 我们可以求出 AR(p) 模型的方差为

$$Var(x_t) = (G_0^2 + G_1^2 + G_2^2 + \cdots) \sigma_\varepsilon^2 \quad (3.10)$$

其中 G_j 满足 (递推可求出)

$$\begin{cases} G_0 = 1 \\ G_j = \sum_{k=1}^j \phi'_k G_{j-k}, \quad j = 1, 2, \cdots \end{cases} \quad \text{式中 } \phi'_k = \begin{cases} \phi_k, & k \leq p \\ 0, & k > p \end{cases} \quad (3.11)$$

例 3.2.3. 求平稳 AR(1) 模型 $x_t = \phi_1 x_{t-1} + \varepsilon_t$, $\varepsilon_t \sim N(0, \sigma_\varepsilon^2)$ 的方差。

解. 根据式 3.11, 我们可以得到

$$G_j = \begin{cases} 1, & j = 0 \\ \phi_1^j, & j = 1, 2, \cdots \end{cases}$$

再根据式3.9, 得 AR(1) 模型的方差为

$$\text{Var}(x_t) = \sum_{j=0}^{\infty} G_j^2 \text{Var}(\varepsilon_t) = \sum_{j=0}^{\infty} \phi_1^{2j} \sigma_\varepsilon^2 = \frac{\sigma_\varepsilon^2}{1 - \phi_1^2}$$

□

3、协方差函数

把方程3.4中式 1 乘 x_{t-k} , 再求期望, 得

$$E(x_t x_{t-k}) = \phi_1 E(x_{t-1} x_{t-k}) + \cdots + \phi_p E(x_{t-p} x_{t-k}) + E(\varepsilon_t x_{t-k})$$

再利用 $E(\varepsilon_t x_{t-k}) = 0$, 得

$$\gamma_k = \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2} + \cdots + \phi_p \gamma_{k-p}, \quad \forall k \geq 1 \quad (3.12)$$

例 3.2.4. 求平稳 AR(1) 模型的协方差。

解. 由递推公式, 我们得

$$\gamma_k = \phi_1 \gamma_{k-1} = \phi_1^k \gamma_0$$

在根据例3.2.3的结果, 带入上式, 得

$$\gamma_k = \phi_1^k \frac{\sigma_\varepsilon^2}{1 - \phi_1^2}, \quad \forall k \geq 1$$

□

例 3.2.5. 求平稳 AR(2) 模型的协方差。

解. 平稳 AR(2) 模型的协方差函数递推公式为

$$\begin{cases} \gamma_0 = \frac{1 - \phi_2}{(1 + \phi_2)(1 - \phi_1 - \phi_2)(1 + \phi_1 - \phi_2)} \sigma_\varepsilon^2 \\ \gamma_1 = \frac{\phi_1 \gamma_0}{1 - \phi_2} \\ \gamma_k = \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2}, k \geq 2 \end{cases}$$

□

4、自相关系数

根据自相关系数的定义 $\rho_k = \frac{\gamma_k}{\gamma_0}$, 我们可以得到

$$\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2} + \cdots + \phi_p \rho_{k-p} \quad (3.13)$$

AR 模型的自相关系数的表达式实际上是一个齐次差分方程, 它的通解形式

$$\rho_k = \sum_{i=1}^p c_i \lambda_i^k \quad |\lambda_i| < 1, \text{ 且 } c_1, \cdots, c_p \text{ 为任意实数}$$

根据自相关系数通解的形式, 我们可以推出如下性质:

- 呈指数衰减: $|\lambda_i| < 1 \Rightarrow \rho_k = \sum_{i=1}^p c_i \lambda_i^k \rightarrow 0$
- 拖尾性: c_1, \cdots, c_p 为任意实数 $\Rightarrow \rho_k = \sum_{i=1}^p c_i \lambda_i^k$ 不会恒等于零, $\forall k >$ 某个常数

例 3.2.6. $AR(1)$ 和 $AR(2)$ 模型的自相关系数递推公式。

解. AR(1) 模型

$$\rho_k = \phi_1^k, k \geq 0$$

AR(2) 模型

$$\rho_k = \begin{cases} 1, & k = 0 \\ \frac{\phi_1}{1-\phi_2} & k = 1 \\ \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2} & k \geq 2 \end{cases}$$

□

5、偏自相关系数

偏自相关系数的定义

$$\rho_{x_t, x_{t-k} | x_{t-1}, \dots, x_{t-k+1}} = \frac{E[(x_t - \hat{E}x_t)(x_{t-k} - \hat{E}x_{t-k})]}{E[(x_{t-k} - \hat{E}x_{t-k})^2]} \quad (3.14)$$

对于方程 $x_t = \phi_{k1}x_{t-1} + \phi_{k2}x_{t-2} + \cdots + \phi_{k(k-1)}x_{t-k+1} + \phi_{kk}x_{t-k}$ 等号两边同时乘 x_{t-l} , 再取期望, 除以方差, 得

取前 k 个方程, 构成 Yule-Walker 方程组, 即

[illegible]

$$\begin{pmatrix} 1 & \rho_1 & \cdots & \rho_{k-1} \\ \rho_1 & 1 & \cdots & \rho_{k-2} \\ \vdots & \vdots & \cdots & \vdots \\ \rho_{k-1} & \rho_{k-2} & \cdots & 1 \end{pmatrix} \begin{pmatrix} \phi_{k1} \\ \phi_{k2} \\ \vdots \\ \phi_{kk} \end{pmatrix} = \begin{pmatrix} \rho_1 \\ \rho_2 \\ \vdots \\ \rho_k \end{pmatrix} \quad (3.16)$$
$$\phi_{kk} = \frac{D_k}{D} \quad (3.17)$$
$$D = \begin{vmatrix} 1 & \rho_1 & \cdots & \rho_{k-1} \\ \rho_1 & 1 & \cdots & \rho_{k-2} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{k-1} & \rho_{k-2} & \cdots & 1 \end{vmatrix}, \quad D_k = \begin{vmatrix} 1 & \rho_1 & \cdots & \rho_1 \\ \rho_1 & 1 & \cdots & \rho_2 \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{k-1} & \rho_{k-2} & \cdots & \rho_k \end{vmatrix}$$

偏自相关系数的截尾性

定理 3.2.8. 平稳 $AR(p)$ 模型的偏自相关系数具有 p 阶结尾性。即 $\Phi_{kk} = 0 (\forall k > p)$ 。

3.3 MA 模型

3.3.1 MA 模型的定义

定义 3.3.1. 具有如下结构的模型称为 q 阶移动平均 (*moving average*) 模型, 简记为 $MA(q)$:

$$\begin{cases} x_t = \mu + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \cdots - \theta_q \varepsilon_{t-q} \\ \theta_q \neq 0 \\ E(\varepsilon_t) = 0, Var(\varepsilon_t) = \sigma_\varepsilon^2, E(\varepsilon_t \varepsilon_s) = 0, s \neq t \end{cases} \quad (3.18)$$

使用 $MA(q)$ 模型需要满足两个限制条件:

- 1、 $\theta_q \neq 0$, 这个限制条件保证了模型的最高阶数为 q 。
- 2、 $E(\varepsilon_t) = 0, Var(\varepsilon_t) = \sigma_\varepsilon^2, E(\varepsilon_t \varepsilon_s) = 0 (s \neq t)$ 。这个条件保证了随机干扰序列 $\{\varepsilon_t\}$ 为零均值白噪声序列。

当 $\mu = 0$ 把模型3.18称为中心化 $MA(q)$ 模型。引入延迟算子, 中心化 $MA(p)$ 模型可以简记为

$$x_t = \Theta(B)\varepsilon_t \quad (3.19)$$

其中 $\Theta(B)$ 称为 q 阶移动平均系数多项式

$$\Theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \cdots - \theta_q B^q$$

3.3.2 MA 模型的统计性质

1、常数均值

$$\begin{aligned}
 & Ex_t \\
 &= E(\mu + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \cdots - \theta_q \varepsilon_{t-q}) \\
 &= \mu
 \end{aligned} \tag{3.20}$$

2、常数方差

$$\begin{aligned}
 Var(x_t) &= Var(\mu + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \cdots - \theta_q \varepsilon_{t-q}) \\
 &= (1 + \theta_1^2 + \cdots + \theta_q^2) \sigma_\varepsilon^2
 \end{aligned} \tag{3.21}$$

3、自协方差函数与自相关系数 q 阶截尾

$$\gamma_k = \begin{cases} (1 + \theta_1^2 + \cdots + \theta_q^2) \sigma_\varepsilon^2, & k = 0 \\ (-\theta_k + \sum_{i=1}^{q-k} \theta_i \theta_{k+i}) \sigma_\varepsilon^2, & 1 \leq k \leq q \\ 0, & k > q \end{cases} \tag{3.22}$$

$$\rho_k = \begin{cases} 1, & k = 0 \\ \frac{-\theta_k + \sum_{i=1}^{q-k} \theta_i \theta_{k+i}}{1 + \theta_1^2 + \cdots + \theta_q^2}, & 1 \leq k \leq q \\ 0, & k > q \end{cases} \tag{3.23}$$

例 3.3.2. 求 $MA(1)$ 模型与 $MA(2)$ 模型的自相关系数。

解. 利用式3.23, 则 MA(1) 模型的自相关系数为

$$\rho_k = \begin{cases} 1 & , k = 0 \\ \frac{-\theta_1}{1+\theta_1^2} & , k = 1 \\ 0 & , k \geq 2 \end{cases} \quad (3.24)$$

则 MA(2) 模型的自相关系数为

$$\rho_k = \begin{cases} 1 & , k = 0 \\ \frac{-\theta_1+\theta_1\theta_2}{1+\theta_1^2+\theta_2^2} & , k = 1 \\ \frac{-\theta_2}{1+\theta_1^2+\theta_2^2} & , k = 2 \\ 0 & , k \geq 3 \end{cases} \quad (3.25)$$

□

3.3.3 MA(q) 模型的可逆性

对于模型 1: $x_t = \varepsilon_t - \theta\varepsilon_{t-1}$ 与模型 2: $x_t = \varepsilon_t - \frac{1}{\theta}\varepsilon_{t-1}$, 我们发现其有相同的自相关系数。即对于不同的 MA(q) 模型, 其自相关系数可能相同。

这种自相关系数的不唯一性, 会给我们将来的工作增加麻烦。因为, 将来我们都是通过样本自相关系数显示出来的特征选择合适的模型拟合序列的发展, 如果自相关系数和模型之间不是一一对应关系, 就将导致拟合模型和随机序列之间不会是一一对应关系。

为了保证一个给定的自相关函数能够对应唯一的模型, 我们就要给模型增加约束条件。这个约束条件称为模型的**可逆性条件**。

定义 3.3.3 (可逆 MA 模型). 若一个 MA 模型能够表示成为收敛的 AR 模型形式, 那么该 MA 模型称为可逆 MA 模型。即一个自相关系数列唯一对应一个可逆 MA 模型。

MA(q) 模型的可逆性条件

MA(q) 模型的可逆概念和 AR(p) 模型的平稳概念是对偶概念。下面给出低阶 MA 模型系数的可逆域。

1、MA(1) 模型的可逆域

$$\{|\theta| - 1 < \theta < 1\}$$

2、MA(2) 模型的可逆域

$$\{\theta_1, \theta_2 | |\theta_2| < 1, \text{ 且 } \theta_2 \pm \theta_1 < 1\}$$

逆函数的递推公式

原理 (把 MA(q) 模型写成如下的两种等价形式):

$$\begin{cases} x_t = \Theta(B)\varepsilon_t \\ \varepsilon_t = I(B)x_t \end{cases} \Rightarrow \Theta(B)I(B)x_t = x_t$$

其中 $I(B)$ 为 $1 + \sum_{k=1}^{\infty} I_k B^k$, 其中使用待定系数法, 求解出递推公式为

$$\begin{cases} I_0 = 1 \\ I_j = \sum_{k=1}^j \theta'_k I_{j-k}, j = 1, 2, \dots \end{cases}, \text{ 其中 } \theta'_k = \begin{cases} \theta_k, k \leq q \\ 0, k > q \end{cases} \quad (3.26)$$

3.3.4 MA 模型偏自相关系数拖尾

一个可逆的 MA(q) 模型可以等价的写成 $AR(\infty)$ 模型形式 (如式3.26)。

AR(p) 模型偏自相关系数 p 阶截尾, 所以可逆的 MA(q) 模型偏自相关系数 ∞ 阶截尾, 即具有偏自相关系数拖尾性。

3.4 ARMA 模型

3.4.1 ARMA 模型的定义

定义 3.4.1. 具有如下结构的模型称为自回归移动平均模型, 简记为 $ARMA(p, q)$

$$\begin{cases} x_t = \phi_0 + \phi_1 x_{t-1} + \cdots + \phi_p x_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \cdots - \theta_q \varepsilon_{t-q} \\ \phi_p \neq 0, \theta_q \neq 0 \\ E(\varepsilon_t) = 0, Var(\varepsilon_t) = \sigma_\varepsilon^2, E(\varepsilon_t \varepsilon_s) = 0, s \neq t \\ E(x_s \varepsilon_t) = 0, \forall s < t \end{cases} \quad (3.27)$$

特别当 $\phi_0 = 0$, 称为中心化 $ARMA(p, q)$ 模型。

引进延迟算子, $ARMA(p, q)$ 模型可以简记为

$$\Phi(B)x_t = \Theta(B)\varepsilon_t \quad (3.28)$$

其中 $\Phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p$, $\Theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \cdots - \theta_q B^q$

3.4.2 平稳条件与可逆条件

ARMA(p, q) 模型的平稳条件

p 阶自回归系数多项式 $\Phi(u) = 0$ 的根都在单位圆外, 其中 $u = \frac{1}{\lambda}$ 。即 $ARMA(p, q)$ 模型的平稳性完全由其自回归部分的平稳性决定。

ARMA(p, q) 模型的可逆条件

q 阶自回归系数多项式 $\Theta(u) = 0$ 的根都在单位圆外, 其中 $u = \frac{1}{\lambda}$ 。即 $ARMA(p, q)$ 模型的可逆性完全由其移动平均部分的可逆性决定。

3.4.3 传递形式与逆转形式

传递形式

$$x_t = \Phi^{-1}(B)\Theta(B)\varepsilon_t = \sum_{j=0}^{\infty} G_j \varepsilon_{t-j} \quad (3.29)$$

其中,

$$\begin{cases} G_0 = 1 & , k = 0 \\ G_k = \sum_{j=1}^k \phi'_j G_{k-j} - \theta'_k & , k \geq 1 \end{cases} \quad \phi'_j = \begin{cases} \phi_j & , 1 \leq j \leq q \\ 0 & , j > q \end{cases}$$

逆转形式

$$\varepsilon_t = \Theta^{-1}(B)\Phi(B)x_t = \sum_{j=0}^{\infty} I_j x_{t-j} \quad (3.30)$$

其中,

$$\begin{cases} I_0 = 1 & , k = 0 \\ I_k = \sum_{j=1}^k \theta'_j I_{k-j} - \phi'_k & , k \geq 1 \end{cases} \quad \theta'_j = \begin{cases} \theta_j & , 1 \leq j \leq q \\ 0 & , j > q \end{cases}$$

3.4.4 ARMA(p,q) 模型的统计性质

均值

$$Ex_t = \frac{\phi_0}{1 - \phi_1 - \cdots - \phi_p} \quad (3.31)$$

协方差

$$\gamma(k) = \sigma_\varepsilon^2 \sum_{i=0}^{\infty} G_i G_{i+k} \quad (3.32)$$

自相关系数

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)} = \frac{\sum_{j=0}^{\infty} G_j G_{j+k}}{\sum_{j=0}^{\infty} G_j^2} \quad (3.33)$$

协方差与自相关系数中的 G_j 的定义如式3.29所示。

3.4.5 ARMA 模型的相关性

自相关系数拖尾性: ARMA(p,q) 模型可以转化为无穷阶移动平均模型。

偏自相关系数拖尾性: ARMA(p,q) 模型可以转化为无穷阶自回归模型。

第四章 平稳序列拟合与预测

4.1 建模步骤

预处理 $\left\{ \begin{array}{l} \text{平稳非白噪声序列} \rightarrow \text{计算 (偏) 自相关系数} \rightarrow \text{模型识别} \\ \text{白噪声序列 (end)} \\ \text{非平稳 (见五、六章)} \end{array} \right.$

\rightarrow 参数估计 \rightarrow 模型检验 $\xrightarrow{\text{通过}}$ 模型优化 \rightarrow 预测

注：若模型检验未通过，则再次进行模型识别。

4.2 单位根检验

4.2.1 DF 检验

- 1、检验对象：存在一阶滞后相关的序列平稳性。
- 2、检验原理：平稳序列 $\{x_t\}$ 的特征根都在单位圆内。
- 3、DF 检验统计量：设 $x_t = \phi_1 x_{t-1} + \xi_t, \xi_t \sim N(0, \sigma^2)$, 特征根为 $\lambda = \phi_1$ 。

$H_0 : \{x_t\}$ 非平稳 vs $H_1 : \{x_t\}$ 平稳

令检验统计量为

$$t(\phi_1) = \frac{\hat{\phi}_1 - \phi_1}{S(\hat{\phi}_1)} \quad (4.1)$$

当 $\phi_1 < 1$ 时, 统计量的渐进分布为标准正态分布, 即

$$t(\phi_1) \xrightarrow{\text{渐近}} N(0, 1) \quad (4.2)$$

当 $|\phi_1| = 1$ 时, 统计量的渐近分布不是我们熟知的任何参数分布, Dickey 和 Fuller 通过随机模拟的方法, 得到该统计量的经验分布

$$\tau = \frac{|\hat{\phi}_1| - 1}{S(\hat{\phi}_1)} \xrightarrow{\text{极限}} \frac{\int_0^1 W(r) dW(r)}{\sqrt{\int_0^1 [W(r)]^2 dr}} \quad (4.3)$$

$W(r)$ 是自由度为 r 的维纳过程 (Weiner process)。

DF 统计量只是一个极限分布的表达式, 无法求出明确的密度函数与分位数。

4、检验方法:

当 $\tau \leq \tau_\alpha$ 时, 拒绝原假设, 认为序列平稳。等价判别是统计量的 P 值小于等于显著性水平 α ;

当 $\tau > \tau_\alpha$ 时, 接受原假设, 认为序列非平稳。等价判别是统计量的 P 值大于显著性水平 α 。

4.2.2 DF 检验的等价表达

令 $\rho = |\phi_1| - 1$, DF 检验可以通过对参数 ρ 的检验等价表达为

$$H_0 : \rho \geq 0 \text{ vs } H_1 : \rho < 0$$

检验统计量为 $\tau = \frac{\hat{\rho}}{S(\hat{\rho})}$ 。

4.2.3 DF 检验的三种类型

类型一: 无漂移项自回归结构, 即

$$x_t = \phi_1 x_{t-1} + \xi_t \quad (4.4)$$

(1) 当 $\phi_1 = 0$ 时, $x_t = \xi_t$ 。若拒绝 H_0 , 则 $\{x_t\}$ 是一个零均值的平稳序列。

(2) 当 $\phi_1 \neq 0$ 时。若拒绝 H_0 , 则 $\{x_t\}$ 是一个零均值一阶自相关的平稳序列。

类型二：有漂移项自回归结构，即

$$x_t = \phi_0 + \phi_1 x_{t-1} + \xi_t \quad (4.5)$$

(1) 当 $\phi_1 = 0$ 时, $x_t = \phi_0 + \xi_t$ 。若拒绝 H_0 , 则 $\{x_t\}$ 是一个均值为 ϕ_0 的平稳序列。

(2) 当 $\phi_1 \neq 0$ 时。若拒绝 H_0 , 则 $\{x_t\}$ 是一个均值为 $\frac{\phi_0}{1-\phi_1}$ 一阶自相关的平稳序列。

类型三：带趋势回归结构，即

$$x_t = \alpha + \beta t + \phi_1 x_{t-1} + \xi_t \quad (4.6)$$

$H_0: \{x_t - \alpha - \beta t\}$ 非平稳。

(1) 若 $\phi_1 = 0$, 此时 $x_t = \alpha + \beta t + \xi_t$ 。若拒绝 H_0 , 则 $\{x_t\}$ 是沿着 $\alpha + \beta t$ 平稳, 也称为趋势平稳, 此时 $E(x_t) = \alpha + \beta t$, $\{x_t\}$ 本身不平稳。

(2) 若 $\phi_1 \neq 0$ 。若拒绝 H_0 , 则 $\{x_t - \alpha - \beta t\}$ 平稳。

注：对于带有趋势项的 $\{x_t\}$, 可取其进行一阶差分, 使其变为平稳序列。

4.2.4 ADF 检验

1、检验对象：任意 p 期确定性信息提取。

$$x_t = \phi_0 + \phi_1 x_{t-1} + \phi_2 x_{t-2} + \dots + \phi_p x_{t-p} + \varepsilon_t$$

2、检验原理：平稳序列 $\{x_t\}$ 的所有特征根都在单位圆内, 即 $|\lambda_i| < 1, i = 1, 2, \dots, p$ 。

3、ADF 检验统计量：令 $\rho = \phi_1 + \phi_2 + \dots + \phi_p - 1$

$$H_0 : \rho \geq 0, \{x_t\} \text{ 非平稳 } vs H_1 : \rho < 0, \{x_t\} \text{ 平稳}$$

构造 ADF 检验统计量

$$\tau = \frac{\hat{\rho}}{S(\hat{\rho})} \quad (4.7)$$

随后的过程与 DF 检验类似。

4.2.5 纯随机性检验

可以参考章节2.3.3, 构造 LB 检验统计量。

$$H_0 : \rho_1 = \dots = \rho_m = 0, \{x_t\} \text{ 纯随机 } vs H_1 : \exists \rho_k \neq 0, \{x_t\} \text{ 非纯随机}$$

4.3 模型识别

设 x_1, x_2, \dots, x_N 为样本观察值。

1、自相关系数

$$\begin{aligned} \hat{\gamma}_k &= \frac{\sum_{j=1}^{N-k} (x_j - \bar{x})(x_{j+k} - \bar{x})}{N}, \quad k = 0, 1, \dots, N-1 \\ \hat{\gamma}_k^* &= \frac{\sum_{j=1}^{N-k} (x_j - \bar{x})(x_{j+k} - \bar{x})}{N-k}, \quad k = 0, 1, \dots, N-1 \end{aligned} \quad (4.8)$$

注: $\hat{\gamma}_k^*$ 为 γ_k 的无偏估计, $\hat{\gamma}_k$ 为 γ_k 的渐进无偏估计。

2、偏自相关系数

$$\phi_{kk} = \frac{D_k}{D}, \quad \hat{\phi}_{kk} = \frac{\hat{D}_k}{\hat{D}} \quad (4.9)$$

4.4 参数估计

设 $x_t = \phi_0 + \phi_1 x_{t-1} + \dots + \phi_p x_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q}$, 共有 $p+q+2$ 个参数。

令 $u = E(x_t)$, $y_t = x_t - u$, 此时的 y_t 为中心化的模型。

4.4.1 矩估计

AR(p) 的矩估计

例 4.4.1. 求 $AR(2)$ 模型 $x_t = \phi_1 x_{t-1} + \phi_2 x_{t-2} + \varepsilon_t$ 的矩估计。

解. $AR(2)$ 模型的 Yule-Walker 方程组为

$$\begin{cases} \rho_1 = \phi_1 + \phi_2 \rho_1 \\ \rho_2 = \phi_1 \rho_1 + \phi_2 \end{cases}$$

解, 得

$$\hat{\phi}_1 = \frac{1 - \hat{\rho}_2}{1 - \hat{\rho}_1^2} \hat{\rho}_1 \quad \hat{\phi}_2 = \frac{\hat{\rho}_2 - \hat{\rho}_1^2}{1 - \hat{\rho}_1^2}$$

□

MA(q) 的矩估计

例 4.4.2. 求 $MA(1)$ 模型 $x_t = \varepsilon_t - \theta_1 \varepsilon_{t-1}$ 得矩估计

解. $MA(1)$ 模型的 Yule-Walker 方程组为

$$\begin{cases} \gamma_0 = (1 + \theta_1^2) \sigma_\varepsilon^2 \\ \gamma_1 = -\theta_1 \sigma_\varepsilon^2 \end{cases} \Rightarrow \rho_1 = \frac{\gamma_1}{\gamma_0} = \frac{-\theta_1}{1 + \theta_1^2}$$

解, 得

$$\hat{\theta}_1 = \frac{-1 + \sqrt{1 - 4\hat{\rho}_1^2}}{2\hat{\rho}_1}$$

□

ARMA(p,q) 的矩估计

例 4.4.3. 求 $ARMA(1,1)$ 模型 $x_t = \phi_1 x_{t-1} + \varepsilon_t - \theta_1 \varepsilon_{t-1}$ 中 ϕ_1 和 θ_1 的估计。

解. ARMA(1,1) 模型的 Yule-Walker 方程组为

$$\begin{cases} \rho_1 = \frac{\gamma_1}{\gamma_0} = \frac{(\phi_1 - \theta_1)(1 - \theta_1\phi_1)}{1 + \theta_1^2 - 2\theta_1\phi_1} \\ \rho_2 = \phi_1\rho_1 \end{cases}$$

把样本自相关系数带入 Yule-Walker 方程组, 得到 ARMA(1,1) 模型参数的矩估计

$$\hat{\phi}_1 = \frac{\hat{\rho}_2}{\hat{\rho}_1}, \hat{\theta}_1 = \begin{cases} \frac{c + \sqrt{c^2 - 4}}{2}, c \leq -2 \\ \frac{c - \sqrt{c^2 - 4}}{2}, c \geq 2 \end{cases}, c = \frac{1 - \phi_1^2 - 2\hat{\rho}_2}{\phi_1 - \hat{\rho}_1}$$

□

4.4.2 极大似然估计

原理: 在极大似然准则下, 认为样本来自使样本出现概率最大的总体。

4.4.3 最小二乘估计

4.5 模型检验

4.5.1 模型的显著性检验

- 1、 目标: 序列的相关信息是否提取充分。
- 2、 对象: 残差序列。
- 3、 残差序列是否为白噪声——纯随机行检验。
- 4、 步骤: 设 $\Phi(B)x_t = \Theta(B)\varepsilon_t$, 则残差 $\varepsilon_t = \Theta(B)^{-1}\Phi(B)x_t$,

$$H_0 : \rho_1 = \dots = \rho_k = 0 \text{ vs } H_1 : \exists k, \rho_k \neq 0$$

检验统计量

$$LB = n(n+2) \sum_{k=1}^m \left(\frac{\hat{\rho}_k^2}{n-k} \right) \sim \chi^2(m)$$

给定 α ，若拒绝 H_0 ，就说明残差序列中还残留着相关信息，拟合的模型不显著。

4.5.2 参数的显著性检验

$$H_0 : \beta_j = 0 \text{ vs } H_1 : \beta_j \neq 0$$

在正态分布假设下， $\hat{\beta}_j \sim N(0, (X^T X)_{jj}^{-1} \sigma_\varepsilon^2)$

$$t = \frac{\hat{\beta}_j}{S_{\hat{\beta}_j}} \sim t(n-m)$$

给定 α ，若拒绝原假设 H_0 ，认为 β_j 显著非零。

4.6 模型优化

4.6.1 AIC 准则

$AIC = n \ln(\hat{\sigma}_\varepsilon) + 2(\text{未知参数个数})$ 使 AIC 函数达到最小的模型被认为是最优模型。

4.6.2 BIC 准则

$BIC = n \ln(\hat{\sigma}_\varepsilon) + \ln(n)(\text{未知参数个数})$ 使 BIC 函数达到最小的模型被认为是最优模型。

注：样本量很大时，选用 SBC 准则。

4.7 序列预测

定义 4.7.1. 根据现有的序列值估计未来某时刻的序列值。(核心: 将来的扰动视为误差) 设 x_t, x_{t-1}, \dots 为观察值, 令 $\hat{x}_t(l)$ 表示 x_{t+l} 的观察值, 其中 l 为预测步长。

4.7.1 线性预测函数

命题 4.7.2. 给定观测值 x_t, x_{t-1}, \dots , 未来任一时刻的估计值都可表示为 $x_i (i = t, t-1, \dots)$ 的线性函数。

事实上, 设 $ARMA(p, q)$ 的逆转形式为

$$\begin{aligned}\varepsilon_t &= \sum_{j=0}^{\infty} I_j x_{t-j} = x_t + \sum_{j=1}^{\infty} I_j x_{t-j} \\ \Rightarrow x_t &= \varepsilon_t - \sum_{j=0}^{\infty} I_j x_{t-j}\end{aligned}$$

由于 $\varepsilon_{t+j} (j \geq 1)$ 不可观测, 故

$$\begin{aligned}\hat{x}_{t+1} &= -I_1 x_t - I_2 x_{t-1} - I_3 x_{t-2} - \dots \\ \hat{x}_{t+2} &= -I_1 \hat{x}_{t+1} - I_2 x_t - I_3 x_{t-1} - \dots \\ \hat{x}_{t+3} &= -I_1 \hat{x}_{t+2} - I_2 \hat{x}_{t+1} - I_3 x_t - \dots \\ \hat{x}_{t+l} &= -I_1 \hat{x}_{t+l-1} - I_2 \hat{x}_{t+l-2} - I_3 \hat{x}_{t+l-3} - \dots\end{aligned}$$

4.7.2 预测方差最小原则

- 1、 预测误差: $e_t(l) = x_{t+l} - \hat{x}_t(l)$
- 2、 预测方差最小: $\text{Var}[e_t(l)] = \min\{\text{Var}[e_t(l)]\}$
- 3、 $ARMA(p, q)$ 预测

由线性预测函数及传递形式, 我们可以推导出当 $\text{Var}[e_t(l)]$ 最小时, 预测值为

$$\hat{x}_t(l) = \sum_{i=0}^{\infty} G_{l+i} \varepsilon_{t-i}, \quad \forall l \geq 1 \quad (4.10)$$

4、误差分析:

$$\begin{aligned} \text{估计误差: } e_t(l) &= \sum_{i=0}^{l-1} G_i \varepsilon_{t+l-i} \\ \text{期望: } E[e_t(l)] &= 0 \\ \text{方差: } \text{Var}[e_t(l)] &= \sum_{i=0}^{l-1} G_i^2 \cdot \sigma_\varepsilon^2 \end{aligned} \quad (4.11)$$

4.7.3 线性最小方差预测的性质

1、条件均值:

命题 4.7.3. 在 x_t, x_{t-1}, \dots 已知条件下, 由预测方差最小原则得到的 $\hat{x}_t(l)$ 是 x_{t+l} 的条件无偏估计。即

$$E(x_{t+l} | x_t, x_{t-1}, \dots) = \hat{x}_t(l) \quad (4.12)$$

2、条件方差

命题 4.7.4. 在 x_t, x_{t-1}, \dots 已知条件下, 由预测方差最小原则得到的 $\hat{x}_t(l)$ 是 x_{t+l} 的条件无偏最小方差的估计值。即

$$\text{Var}(x_{t+l} | x_t, x_{t-1}, \dots) = \text{Var}[e_t(l)] = \sum_{i=0}^{l-1} G_i^2 \delta_\varepsilon^2 \quad (4.13)$$

3、置信区间在正态分布假设下, 给定 $\alpha, x_{t+l} | x_t, x_{t-1}, \dots \sim N(\hat{x}_t(l), \sum_{i=0}^{l-1} G_i^2 \delta_\varepsilon^2)$ 。

置信度为 $1 - \alpha$ 的置信区间为: $\hat{x}_t(l) \pm 1.96 \sqrt{\sum_{i=0}^{l-1} G_i^2 \delta_\varepsilon^2}$

4、AR(p) 序列预测

$$\hat{x}_t(l) = \sum_{i=1}^p \phi_i \hat{x}_t(l-i) \quad (4.14)$$

其中 $\hat{x}_t(k) = \begin{cases} \hat{x}_t(k) & k \geq 1 \\ x_{t+k} & k < 0 \end{cases}$ 。

预测方差为 $\text{Var}[e_t(l)] = (1 + G_1^2 + \cdots + G_{l-1}^2)\sigma_\varepsilon^2$ 。

5、MA(q) 序列预测

$$\hat{x}_t(l) = \begin{cases} \mu - \sum_{i=l}^q \theta_i \varepsilon_{t+l-i} & , l \leq q \\ \mu & , l > q \end{cases} \quad (4.15)$$

预测方差为

$$\text{Var}[e_t(l)] = \begin{cases} (1 + \theta_1^2 + \cdots + \theta_{l-1}^2)\sigma_\varepsilon^2 & , l \leq q \\ (1 + \theta_1^2 + \cdots + \theta_q^2)\sigma_\varepsilon^2 & , l > q \end{cases} \quad (4.16)$$

6、ARMA(p,q) 序列预测

$$\begin{aligned} \hat{x}_t(l) &= E(\phi_1 x_{t+l-1} + \cdots + \phi_p x_{t+l-p} + \varepsilon_{t+l} - \theta_1 \varepsilon_{t+l-1} - \cdots - \theta_q \varepsilon_{t+l-q} \mid x_t, x_{t-1}, \dots) \\ &= \begin{cases} \phi_1 \hat{x}_t(l-1) + \cdots + \phi_p \hat{x}_t(l-p) - \sum_{i=l}^q \theta_i \varepsilon_{t+l-i}, & l \leq q \\ \phi_1 \hat{x}_t(l-1) + \cdots + \phi_p \hat{x}_t(l-p), & l > q \end{cases} \end{aligned} \quad (4.17)$$

其中, $\hat{x}_t(k) = \begin{cases} \hat{x}_t(k) & k \geq 1 \\ x_{t+k} & k \leq 0 \end{cases}$ 。

预测方差为 $\text{Var}[e_t(l)] = (G_0^2 + G_1^2 + \cdots + G_{l-1}^2)\sigma_\varepsilon^2$ 。

7、修正预测

1、在旧信息的基础上, x_{t+l} 的预测值为

$$\hat{x}_t(l) = G_l \varepsilon_t + G_{l+1} \varepsilon_{t-1} + \cdots$$

2、假设新获得一个观察值 x_{t+1} , 则

• x_{t+l} 的修正预测值为

$$\hat{x}_{t+1}(l-1) = G_{l-1} \varepsilon_{t+1} + G_l \varepsilon_t + G_{l+1} \varepsilon_{t-1} + \cdots = G_{l-1} \varepsilon_{t+1} + \hat{x}_t(l)$$

- 修正预测误差为

$$e_{t+1}(l-1) = G_0\varepsilon_{t+l} + \cdots + G_{l-2}\varepsilon_{t+2}$$

- 预测方差为

$$\text{Var}[e_{t+1}(l-1)] = (G_0^2 + \cdots + G_{l-2}^2)\sigma_\varepsilon^2$$

3、 假设新获得 p 个观察值 x_{t+1}, \cdots, x_{t+p} , 则

- x_{t+l} 的修正预测值为

$$\hat{x}_{t+p}(l-p) = G_{l-p}\varepsilon_{t+p} + \cdots + G_{l-1}\varepsilon_{t+1} + \hat{x}_t(l) \quad (4.18)$$

- 修正预测误差为

$$e_{t+p}(l-p) = G_0\varepsilon_{t+l} + \cdots + G_{l-p-1}\varepsilon_{t+p+1} \quad (4.19)$$

- 预测方差为

$$\text{Var}[e_{t+p}(l-p)] = (G_0^2 + \cdots + G_{l-p-1}^2)\sigma_\varepsilon^2 \quad (4.20)$$

第五章 无季节效应的非平稳序列分析

5.1 Crammer 分解定理

定义 5.1.1. 任何一个时间序列 x_t 都可以分解为两部分的叠加：一部分是由时间 t 的多项式决定的确定性成分，另一部分是由白噪声序列决定的随机性成分。即

$$\begin{aligned} x_t &= \mu_t + \varepsilon_t \\ &= \sum_{j=0}^d \beta_j t^j + \Psi(B)a_t \end{aligned} \tag{5.1}$$

其中 μ_t 为确定性影响， ε_t 为随机性影响。

注 1：Crammer 分解定理表明非平稳时间序列分解成的两部分，至少有一部分是平稳的。

注 2： $E\varepsilon_t = 0$ 。

5.2 差分平稳

5.2.1 差分运算的实质

Cramer 分解定理在理论上保证了适当阶数的差分一定可以充分提取确定性信息：

$$\nabla^d \sum_{j=0}^d \beta_j t^j = c, c \text{ 为某一常数}$$

差分运算的实质是使用自回归的方式提取确定性信息：

$$\nabla^d x_t = (1 - B)^d x_t = \sum_{i=0}^d (-1)^i C_d^i x_{t-i}$$

5.2.2 差分方式的选择

- 1、 序列蕴含着显著的线性趋势，通常一阶差分就可以实现趋势平稳；
- 2、 序列蕴含着曲线趋势，通常低阶（二阶或三阶）差分就可以提取出曲线趋势的影响；
- 3、 对于蕴含着固定周期的序列，进行步长为周期长度的差分运算，通常可以较好地提取周期信息。

5.2.3 过差分

- 从理论上而言，足够多次的差分运算可以充分地提取原序列中的非平稳确定性信息；
- 但应当注意的是，差分运算的阶数并不是越多越好。因为差分运算是一种对信息的提取、加工过程，每次差分都会有信息的损失，方差变大；
- 在实际应用中差分运算的阶数得适当，应当避免过度差分的现象。

5.3 ARIMA 模型

5.3.1 模型结构

$$\begin{cases} \Phi(B)\nabla^d x_t = \Theta(B)\varepsilon_t \\ E(\varepsilon_t) = 0, \text{Var}(\varepsilon_t) = \sigma_\varepsilon^2, E(\varepsilon_t \varepsilon_s) = 0, s \neq t \\ Ex_s \varepsilon_t = 0, \forall s < t \end{cases} \quad (5.2)$$

记作 $\text{ARIMA}(p, d, q)$ 。

当 $p = 0, d = 1, q = 0$ 时, 此时的模型称为**随机游走模型**, 模型结构为

$$\begin{cases} x_t = x_{t-1} + \varepsilon_t \\ E(\varepsilon_t) = 0, \text{Var}(\varepsilon_t) = \sigma_\varepsilon^2, E(\varepsilon_t \varepsilon_s) = 0, s \neq t \\ Ex_s \varepsilon_t = 0, \forall s < t \end{cases}$$

5.3.2 ARIMA 模型的平稳性

$\Phi(B)(1-B)^d = 0$, 其中 $\Phi(B)$ 的 p 个特征根在单位圆内, 而 $(1-B)^d = 0$ 有 d 个为 1 的重根。故当 $d \neq 0$ 时, ARIMA 模型不平稳。

5.3.3 ARIMA 模型建模步骤

具体步骤如图5.1所示。

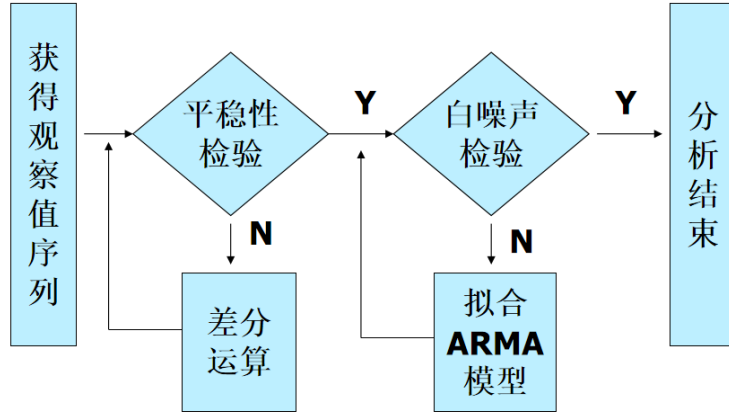


图 5.1 ARIMA 模型建模步骤

5.3.4 ARIMA 模型预测

ARIMA(p,d,q) 模型的一般表示方法为 $\Phi(B)(1-B)^d x_t = \Theta(B)\varepsilon_t$, 如果把 $\Phi^*(B)$ 记为广义自相关函数, 则有

$$\Phi^*(B) = \Phi(B)(1-B)^d = 1 - \tilde{\phi}_1 B - \tilde{\phi}_2 B^2 - \dots$$

和 ARMA 模型一样, 也可以用随机扰动项的线性函数表示它 (Green 函数)

$$x_t = \varepsilon_t + \Psi_1 \varepsilon_{t-1} + \Psi_2 \varepsilon_{t-2} + \dots$$

其 Green 函数的递推公式为

$$\begin{cases} \Psi_1 = \tilde{\phi}_1 - \theta_1 \\ \Psi_2 = \tilde{\phi}_1 \Psi_1 + \tilde{\phi}_2 - \theta_2 \\ \vdots \\ \Psi_j = \tilde{\phi}_1 \Psi_{j-1} + \dots + \tilde{\phi}_{p+d} \Psi_{j-p-d} - \theta_j \end{cases}$$

$$\text{其中 } \Psi_j = \begin{cases} 0, & j < 0 \\ 1, & j = 0 \end{cases}, \theta_j = 0, j > q$$

5.3.5 预测值

与章节4.7类似, 对序列值 x_{t+l} 进行分解, 得

$$x_{t+l} = (\varepsilon_{t+l} + \Psi_1\varepsilon_{t+l-1} + \cdots + \Psi_{l-1}\varepsilon_{t+1}) + (\Psi_l\varepsilon_t + \Psi_{l+1}\varepsilon_{t-1} + \cdots)$$

其中 $e_t(l) = \varepsilon_{t+l} + \Psi_1\varepsilon_{t+l-1} + \cdots + \Psi_{l-1}\varepsilon_{t+1}$,

$$\hat{x}_t(l) = \Psi_l\varepsilon_t + \Psi_{l+1}\varepsilon_{t-1} + \Psi_{l+2}\varepsilon_{t-2} + \cdots$$

5.4 疏系数模型

ARIMA(p,d,q) 模型是指 d 阶差分后自相关最高阶数为 p, 移动平均最高阶数为 q 的模型, 通常有 $p+q$ 个独立的未知系数: $\phi_1, \cdots, \phi_p, \theta_1, \cdots, \theta_q$ 。

如果该模型中有部分自相关系数或部分移动平滑系数为零, 即原模型中有部分系数省缺了, 那么该模型称为**疏系数模型**。

5.4.1 疏系数模型的类型

- 如果只是自相关部分有省缺系数, 那么该疏系数模型可以简记为

$$ARIMA((p_1, \cdots, p_m), d, q)$$

其中, p_1, \cdots, p_m 为非零自相关系数的阶数。

- 如果只是移动平滑部分有省缺系数, 那么该疏系数模型可以简记为

$$ARIMA(p, d, (q_1, \cdots, q_n))$$

其中, q_1, \cdots, q_n 为非零移动平滑系数的阶数。

- 如果自相关和移动平滑部分都有省缺, 可以简记为

$$ARIMA((p_1, \cdots, p_m), d, (q_1, \cdots, q_n))$$

示例见图5.2。

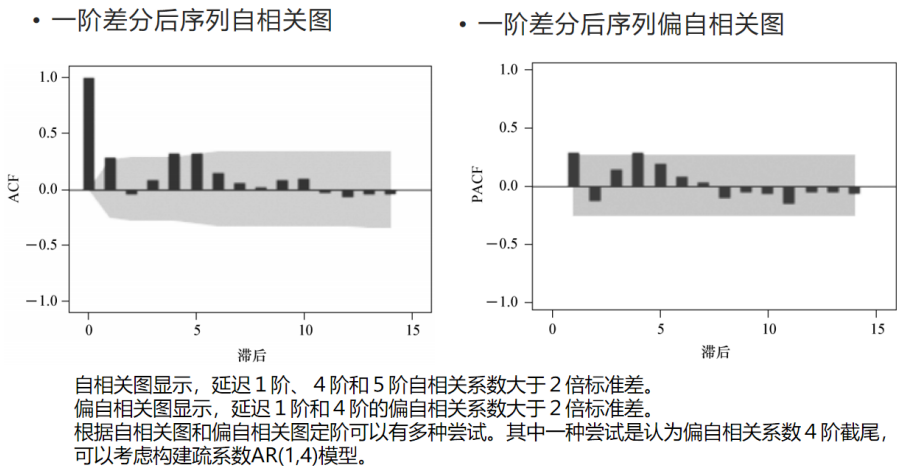


图 5.2

参考文献

- [1] 詹姆斯.D. 汉密尔顿, 时间序列分析 (上册), 中国人民大学出版社
- [2] 王黎明, 王连等, 应用时间序列分析 (第二版) 复旦大学出版社,2019
- [3] 易丹辉, 时间序列分析方法与应用 (第二版), 中国人民大学出版社, 2018
- [4] 史代敏, 谢小燕, 应用时间序列分析, 高等教育出版社,2016