

非参数统计分析

作者: Lollins

时间: November 17, 2023



改变人生的事情, 你必须冒险; 意义非凡的事情, 大多碰巧发生; 不重要的事, 才有周全的计划。

前言

非参数统计分析笔记,一些图片的代码在 code 文件夹下。

Lollins November 17, 2023

目录

弗Ⅰ草	拓 伦	1
1.1	序	1
	1.1.1 非参数统计概念及学习意义	1
	1.1.2 非参数统计的历史及发展	1
1.2	引言	1
	1.2.1 参数统计方法与非参数统计方法的区别	1
	1.2.2 非参数统计方法的特点	1
第2章	描述性统计	2
2.1	图表法	2
2.2	数值方法	2
	2.2.1 表示中心位置的数值	2
	2.2.2 表示离散程度的数值	3
	2.2.3 标准误	3
	2.2.4 偏度	3
	2.2.5 峰度	3
第3章	符号检验法	5
3.1	符号检验	5
	3.1.1 具体操作方法	5
	3.1.2 注意事项	5
	3.1.3 中位数的估计	5
3.2	符号检验在定性数据分析中的应用	6
3.3	成对数据的比较问题	6
公 4 立	グロ升 和 A A A A A	_
	符号秩和检验法	7
4.1	对称中心为原点的检验问题	7
	4.1.1 符号秩和检验统计量 W ⁺	7
	4.1.2 符号秩和检验	7
4.2	符号秩和检验统计量 W ⁺ 的性质	
	4.2.1 概率分布	8
	4.2.2 W ⁺ 分布的对称性	8
4.3	符号秩和检验统计量 W^+ 的渐进正态性 \dots	8
	4.3.1 期望与方差	8
	4.3.2 W ⁺ 渐进正态性	9
4.4	平均秩法	9
	4.4.1 定义	9
	4.4.2 性质	9
4.5	对称中心的点估计	9
公 - 立		1.
		11
5.1	Mood 中位数检验法 (2 × 2 列联表检验法)	
	5.1.1 Mood 中位数检验法	11

F	구.

5.1.2 大样本情形 11

第1章 绪论

1.1 序

1.1.1 非参数统计概念及学习意义

1.1.1.1 意义

1.1.1.2 概念

- 参数统计方法:数据样本被视为从分布族的某个参数族抽取出来的总体的代表,未知的仅仅是总体分布具体数值,这样推断问题就转化为分布族的若干未知参数的估计问题,用样本来对这些参数进行估计或进行假设检验,从而得知背后的分布,这类推断方法称为参数统计方法。
- **非参数统计方法**:不假定总体分布的具体形式,尽量从数据(或样本)本身获得所需要的信息,通过估计 而获得分布的结构,并逐步建立对事物的数学描述和统计模型的方法。

1.1.2 非参数统计的历史及发展

1.2 引言

1.2.1 参数统计方法与非参数统计方法的区别

- **参数统计方法**:假定总体的分布形式,既利用样本的数据信息,又利用产生数据总体的信息,是一个有效的数据分析方法,针对性强,但可能出现大的错误。
- 非参数统计方法: 不假定总体的分布形式, 更接近大多数实际情况, 故不会出现大的错误。

1.2.2 非参数统计方法的特点

- (1) 有广泛的适用性(广)
- (2) 样本方法是非参数统计的基本方法(样本)
- (3) 计算简单(简)
- (4) 良好的稳定性(稳)

第2章 描述性统计

定义 2.1 (描述性统计)

是在对产生数据的总体的分布不作任何假设的情况下,整理数据、显示数据、分析数据,将数据中有用的信息提取出来的统计方法。本章介绍常用的描述性统计方法:表格法、图形法和数值方法。

2.1 图表法

表格法、图形法描述统计数据主要是频数 (率)分布表和直方图。

2.2 数值方法

数值方法主要是用数值来表示数据的中心位置和离散程度等的方法。

2.2.1 表示中心位置的数值

我们要求数据的中心位置满足这样一个**条件**:它到各个数据点的距离的和比较小。表示中心位置的数值有平均数、中位数、众数、切尾平均数。

2.2.1.1 平均数

如果用平方值距离法,则点 a 到各数据点 $x_1, x_2, ..., x_n$ 的距离的和可以用 $\sum_{i=1}^n (x_i - a)^2$ 来衡量。平均数 $\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$ 满足条件:

$$\sum_{i=1}^{n} (x_i - \bar{x})^2 = \min_{a} \sum_{i=1}^{n} (x_i - a)^2$$
(2.1)

上式表示平均数这一点到各个数据点的平方值距离和最短。所以在平方值距离方法下,数据中心位置的代表是平均数。

2.2.1.2 中位数

如果用绝对值距离法,则点 a 到各数据点 $x_1, x_2, ..., x_n$ 的距离的和可以用 $\sum_{i=1}^n |x_i - a|$ 来衡量,中位数 me 满足条件:

$$\sum_{i=1}^{n} |x_i - \max| = \min_{a} \sum_{i=1}^{n} |x_i - a|$$
 (2.2)

上式表示**中位数这一点到各个数据点的绝对值距离和最短**。所以在**绝对值距离方法下**,数据中心位置的代表是**中位数**。

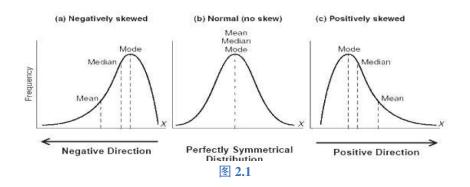
注:

- 中位数是非线性规划选址问题的解;
- 中位数不受极大(小)的影响,有时能较好地表示数据的中心位置。

2.2.1.3 众数

众数:一组数据中出现频数最高的数据。

注:



- 众数也能描述数据的中心位置。特别是定性数据;
- 一组数据有偏时,若数据右偏 (Positively Skewed),通常有 $mo < me < \bar{x}$,若数据左偏 (Negatively Skewed),通常有 $\bar{x} < me < mo$,见图2.1。

2.2.1.4 切尾平均数

设 $X_{(1)},...,X_{(n)}$ 是来自总体 X 的简单随机样本 $X_1,...,X_n$ 的次序统计值,称

$$T_{nk} = \frac{1}{n - 2k} (x_{(k+1)} + \dots + x_{(n-k)})$$
(2.3)

为原样本的的切尾均值。

2.2.2 表示离散程度的数值

样本方差、标准差、全距(范围)、四分位数间距。

2.2.3 标准误

$$se = \frac{s}{\sqrt{n}}, s$$
为样本标准差 (2.4)

2.2.4 偏度

偏度反映单峰分布对称性,常用 β 。表示总体偏度,

$$\beta_s = E[(\frac{x-\mu}{\sigma})^3] = \frac{\mu_3}{\sigma^3}, \sharp + \mu_3 = E(x-\mu)^3$$
 (2.5)

注: 对称分布的偏度 $\beta_s=0$; 反之不成立,即 $\beta_s=0$,不一定是对称分布。

样本偏度用 b_s 表示,

$$b_s = \frac{m_3}{m_2^{\frac{3}{2}}}, \sharp + m_j = \frac{1}{n} \sum_i (x_i - \overline{x})^j$$
 (2.6)

注: $b_s > 0$ 时,倾向于认为数据分布右偏; $b_s < 0$ 时,倾向于认为数据分布左偏; $b_s \approx 0$ 时,倾向认为数据分布是对称的。

2.2.5 峰度

峰度反映分布峰的尖峭程度,常用 β_k 表示总体峰度。

$$\beta_k = E[(\frac{x-\mu}{\sigma})^4] = \frac{\mu_4}{\sigma^4}$$
 (2.7)

注: 若 $X \sim N(\mu, \sigma^2)$,则 $\beta_k = 3$ 。当 $\beta_k > 3$ 时,该分布具有过度的峰度 (厚尾分布),当 $\beta_k < 3$ 时,该分布具有不足的峰度 (薄尾分布),

样本峰度用 b_k 表示,

$$b_k = \frac{m_4}{(m_2)^2} (2.8)$$

第3章 符号检验法

在非参数检验中,总体的中心位置的数通常用中位数表示,本章主要讨论中位数、p分位数检验问题的符号检验方法,中位数的点估计、区间估计等。

3.1 符号检验

3.1.1 具体操作方法

符号检验问题的原假设和备择假设有三种情况。这三种情况的原假设 H_0 都是 $me = me_0$,其中 me_0 是给定的常数,备择假设 H_1 分别是 $me > me_0$, $me < me_0$ 和 $me \neq me_0$ 。

由于 P(X = me) = 0,所以不妨假设样本单元 $x_1, x_2, ..., x_n$ 都不等于 me_0 。符号检验的检验统计量为

$$S^{+} = {}^{\#}G = {}^{\#}\{x_i : x_i - me_0 > 0, i = 1, 2, \cdots, n\},$$
(3.1)

记号#表示计数,即 S^+ 是集合G中元素的个数。 S^+ 也可以等价的表示为

$$S^{+} = \sum_{i=1}^{n} u_{i}, u_{i} = \begin{cases} 1, & x_{i} - me_{0} > 0 \\ 0, & \text{ figure}, \end{cases}, \quad i = 1, 2, \dots, n$$
(3.2)

由于在 $me = me_0$ 时, $S^+ \sim b(n, \frac{1}{2})$ 。

考虑备择假设 $H_1: me > me_0$,我们用 p 值来度量 S^+ 是否足够大,让我们拒接原假设。p 值等于二项分布 $b(n, \frac{1}{2})$ 的随机变量大于等于 S^+ 的概率 $P(b(n, \frac{1}{2}) \geq S^+)$,p 值越小, S^+ 越大。

如果 p 值 $\leq \alpha$,则在显著性水平 α 下拒接原假设,认为备择假设 H_1 成立;如果 p 值 $> \alpha$,则在显著性水平 α 下不拒绝原假设。

3.1.2 注意事项

在实际问题中,可能出现一些观察值正好等于 me_0 ,这时有以下两种处理方法:

- 1、 将这些正好等于 me_0 的观察值去掉,并相应的减少样本容量 n 的值。
- 2、(不常用,不写了)

3.1.3 中位数的估计

3.1.3.1 点估计

引理 3.1

设 $x_1, x_2, ..., x_n$ 是来自总体 X 的样本, t_p 为总体 X 的 p 分位数, m_{np} 为样本的 p 分位数, 则

$$P(\lim_{n \to \infty} m_{np} = t_p) = 1 \tag{3.3}$$

根据引理3.1,我们可以结论

$$\hat{t}_p = m_{np} = \begin{cases} x_{([np]+1)}, & np \text{ if } p \text{ if$$

3.1.3.2 区间估计

设 $x_1,x_2,...,x_n$ 是来自总体 X 的样本, $S^+={}^\#\{x_i:x_i-{\sf me}_0>0,i=1,2,\cdots,n\}\sim b(n,\frac{1}{2})$ 那么有

$$P(x_{(r)} \le me \le x_{(n-r+1)}) = 1 - P(me < x_{(r)}) - P(me > x_{(n-r+1)}) = 1 - \sum_{i=0}^{r-1} \binom{n}{i} (\frac{1}{2})^{n-1}$$
(3.5)

注:层数 r 越大,置信区间越短,置信水平越低 (置信水平为 $1-\alpha$)。

3.2 符号检验在定性数据分析中的应用

根据中心极限定理, 当 n 很大时, 且 $S^+ \sim b(n,p)$, 那么 $z = \frac{S^+ - np}{\sqrt{np(1-p)}} \sim N(0,1)$ 。

1.
$$P(X \le k) \approx \Phi(\frac{k + \frac{1}{2} - np}{\sqrt{np(1-p)}}), P(X < k) \approx \Phi(\frac{k - \frac{1}{2} - np}{\sqrt{np(1-p)}})$$

对于
$$x \sim b(n,p)$$
,做连续性修正:

1、 $P(X \le k) \approx \Phi(\frac{k+\frac{1}{2}-np}{\sqrt{np(1-p)}}), P(X < k) \approx \Phi(\frac{k-\frac{1}{2}-np}{\sqrt{np(1-p)}})$

2、 $P(X \ge k) \approx \Phi(\frac{np-k+\frac{1}{2}}{\sqrt{np(1-p)}}), P(X > k) \approx \Phi(\frac{np-k-\frac{1}{2}}{\sqrt{np(1-p)}})$

3.3 成对数据的比较问题

定义 3.1 (配对数据)

两样本间配偶成对, 每一对样本除随机给予的不同处理外, 其他试验条件尽量一致。

第4章 符号秩和检验法

本章主要讨论对称中心的检验及估计问题。

4.1 对称中心为原点的检验问题

4.1.1 符号秩和检验统计量 W^+

符号检验统计量

$$S^{+} = \sum_{i=1}^{n} u_{i}, u_{i} = \begin{cases} 1, & x_{i} > 0, \\ 0, & \text{ figure } i = 1, 2, \dots, n. \end{cases}$$

$$(4.1)$$

注: S+ 仅使用样本数据量的正负信息,未使用样本数据量的大小信息。

符号秩和统计量

设 $|x_1|, |x_2|, \cdots, |x_n|$ 互不相等,由大到小排列为 $z_{(1)} < z_{(2)} < \cdots < z_{(n)}$,若 $|x_i| = z_{(R_i)}$,则称 $|x_i|$ 的秩为 $R_i, R_i = 1, 2, \cdots, n$ 。符号秩和统计量为

$$W^{+} = \sum_{i=1}^{n} u_i R_i \tag{4.2}$$

此处的 u_i 定义与式4.1中相同。

在表4.1中给出了10个观察值以及它们的10个观察值的符号,绝对值和绝对值的秩。这10个观察值的符号

_	观察值	-7.6	-5.5	4.3	2.7	-4.8	2.1	-1.2	-6.6	-3.3	-8.5
	符号	-	-	+	+	-	+	-	-	-	-
	绝对值	7.6	5.5	4.3	2.7	4.8	2.1	1.2	6.6	3.3	8.5
- :	绝对值的秩	9	7	5	3	6	2	1	8	4	10

表 4.1: 10 个观察值的符号,绝对值和绝对值的秩

检验统计量 $S^+ = 3$, 符号秩和统计量 $W^+ = 5 + 3 + 2 = 10$ 。

4.1.2 符号秩和检验

检验统计量: W^+ , 原假设 $H_0: \theta = 0$

1、备择假设 $H_1: \theta > 0$,若备择假设 H_1 成立,则 $\forall a > \theta$,有 P(x > a) > P(x < -a)。如图4.1所示,代码 见 im4_1.r。

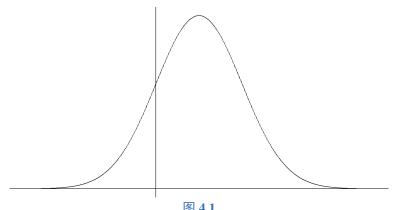


图 4.1

给定置信水平 α , 拒绝域为 $W^+ \geq c$, 其中

$$c = \inf\{c^* : P(W^+ \geqslant c^+) \leqslant \alpha\}$$

2、备择假设 $H_1: \theta < 0$, 拒绝域为 $W^+ \leq d$, 其中

$$d = \sup\{d^* : P(W^+ \le d^*) \le \alpha\}$$

3、备择假设 $H_1:\neq 0$,拒绝域为 $W^+\geq c$ 或 $W^+\leq d$,其中

$$c = \inf\{c^* : P(W^+ \ge c^*) \le \alpha/2\}, d = \sup\{d^* : P(W^+ \le d^*) \le \alpha/2\}.$$

4.2 符号秩和检验统计量 W^+ 的性质

4.2.1 概率分布

命题 4.1

令 $S = \sum_{i=1}^{n} iu_i$,则在总体关于原点对称时, W^+ 和 S 同分布,即 $W^+ \stackrel{d}{=} S$ 。

注: 总体 X 的分布关于原点对称时, $u_1, u_2, ..., u_n$ 相互独立同分布,且 $P(u_i = 0) = P(u_i = 1) = \frac{1}{2}, i = 1, 2, ..., n$ 。故 $S = \sum_{i=1}^{n} i u_i$ 为离散型分布,它的取值范围为 $0, 1, ..., \frac{n(n+1)}{2}$,并且

$$P(S=d) = P(\sum_{i=1}^{n} iu_i = d) = \frac{t_n(d)}{2^n}, d = 0, 1, 2, \dots, \frac{n(n+1)}{2}$$
(4.3)

其中 $t_n(d)$ 表示从 1,2,...,n 中任取若干个数,其和恰为 d 的取法数量 (其中 $t_n(d) = t_n(\frac{n(n+1)}{2} - d)$)。

4.2.2 W^+ 分布的对称性

命题 4.2

在总体的分布关于原点 0 对称时, W^+ 服从对称分布,对称中心为 $0,1,...,rac{n(n+1)}{2}$ 的中点 $rac{n(n+1)}{4}$

注: 当 $n \leq 30$ 时,可查表得到符号秩和检验临界值 c_{α} ,使 $P(W^+ \geq c_{\alpha}) = \alpha$,故当 $d = \frac{n(n+1)}{2} - c_{\alpha}$ 时, $P(W^+ \leq d_{\alpha}) = \alpha$ 。

4.3 符号秩和检验统计量 W^+ 的渐进正态性

4.3.1 期望与方差

$$H_0$$
 成立时, $W^+ \stackrel{d}{=} S = \sum_{i=1}^n i u_i$, $u_i \sim \begin{pmatrix} 0 & 1 \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}$ 。 再根据 $E(u_i) = \frac{1}{2}, D(u_i) = \frac{1}{4}$,求得 S 的期望与方差为
$$E(S) = \frac{1}{2} \sum_{i=1}^n i = \frac{n(n+1)}{4},$$

$$D(S) = \frac{1}{4} \sum_{i=1}^n i^2 = \frac{n(n+1)(2n+1)}{24}.$$
 (4.4)

由于 W^+ 与S有相同的分布,所以我们求得了 W^+ 的均值与方差。

命题 4.3

在总体分布关于原点 0 对称时,

$$E(W^{+}) = \frac{n(n+1)}{4},$$

$$D(W^{+}) = \frac{n(n+1)(2n+1)}{24}.$$
(4.5)

4.3.2 W⁺ 渐进正态性

由 liapunov 中心极限定理知 S 渐进服从正态分布,而 W^+ 与 S 有相同的分布,所以 W^+ 也有渐进正态性。

命题 4.4

如果总体的分布关于原点 0 对称,则在样本容量 n 趋于无穷大时, W^+ 也有渐进正态性,即

$$\frac{W^{+} - E(W^{+})}{\sqrt{D(W^{+})}} = \frac{W^{+} - n(n+1)/4}{\sqrt{n(n+1)(2n+1)/24}} \xrightarrow{L} N(0,1)$$
(4.6)

该渐进正态性简记为

$$W^{+} \dot{\sim} N(\frac{n(n+1)}{4}, \frac{n(n+1)(2n+1)}{24})$$
 (4.7)

4.4 平均秩法

4.4.1 定义

定义 4.1

设 $x_1,x_2,...,x_n$ 为取自总体 X 的样本,其中相等的 x_i 组成一个结,结中 x_i 的个数称为该结的结长 $\tau(\geq 2)$,结的个数记为 q。

秩的定义方式: 随机秩, 平均秩。

4.4.2 性质

命题 4.5

若总体 X 的分布关于原点对称,有结数据取平均秩,则

$$E(W^{+}) = \frac{n(n+1)}{4},$$

$$D(W^{+}) = n(n+1)\left((2n+1)/24 - \sum_{j=1}^{g} \left(\tau_{j}^{3} - \tau_{j}\right)/48.$$
(4.8)

注: 有结数据取平均秩, W^+ 依旧服从渐进正态分布。

4.5 对称中心的点估计

- 1、样本的均值估计对称中心 θ 。
- **2、**样本的中位数估计对称中心 θ 。
- 3、样本的切尾均值估计对称中心 θ 。
- **4、**Winsort 化样本的均值估计对称中心 θ 。

定义 4.2

设 $x_1, x_2, ..., x_n$ 的次序统计量为 $x_{(1)}, x_{(2)}, ..., x_{(n)}$, 称

$$W_{nk} = \frac{1}{n} \left(\sum_{i=k+1}^{n-k} x_{(1)} + kx_{(k+1)} + kx_{(n-k)} \right)$$
 (4.9)

为对称中心的 Winsort 化均值估计。

注: Winsort 化均值估计为切尾均值的一个修正,它加重了端头值在估计中的权重。

5、Hodges Lehmann(H-L) 估计

H-L 估计对称中心步骤如下:

- (i) 先构造统计量 $T = T(x_1, x_2, ..., x_n)$ 满足一下性质:
 - $\theta = 0$ 时,T 的分布关于某点 c 对称,且与 x 分布函数 F(x)。
 - 任意 $x_1, x_2, ..., x_n \in R$ 时, $T(x_1 + \theta, x_2 + \theta, ..., x_n + \theta)$ 关于 θ 非降。
- (ii) 定义:

$$\hat{\theta}_1 = \sup\{a : T(x_1 - a, x_2 - a, ..., x_n - a) > c\}$$

$$\hat{\theta}_2 = \sup\{a : T(x_1 - a, x_2 - a, ..., x_n - a) < c\}$$
(4.10)

一般有 $\hat{\theta}_1 \leq \hat{\theta}_2$ 。

(iii) 令 $\theta = \frac{\hat{\theta}_1 + \hat{\theta}_2}{2}$ 作为对称中心 θ 的估计。

常用对称中心 H-L 估计量如下:

- (1) 当 T 统计量为 $T = \frac{\sqrt{n}\bar{x}}{S}$ 时, $\hat{\theta} = \bar{x}$;
- (2) 当 T 统计量为 $T = S^+ = \{x_i > 0, i = 1, 2, ..., n\}$ 时, $\hat{\theta} = m_n$ (中位数);
- (3) 当 T 统计量为 $T=W^+$ 时,将 $\{\frac{x_i+x_j}{2},1\leq i\leq j\leq n\}$,共有 $N=\frac{n(n+1)}{2}$ 个值,从小到大排序为 $W_{(1)}^+\leq W_{(2)}^+\leq ...\leq W_{(N)}^+$,则称对称中心 θ 的 H-L 估计为 $\{\frac{x_i+x_j}{2},1\leq i\leq j\leq n\}$ 的中位数。

第5章 两样本问题

5.1 Mood 中位数检验法 (2×2) 列联表检验法)

5.1.1 Mood 中位数检验法

样本 $x_1,...,x_m$ 和 $y_1,...,y_n$ 分别来自相互独立的连续型总体 X 和 Y,分别记其中位数为 me_x,me_y 。($H_0:me_x=me_y$)

首先将样本 $x_1,...,x_m$ 和 $y_1,...,y_n$ 合在一起,并从小到大排列,计算混合样本中位数 m_n ,得四格表

表 5.1

	$\leq m_n$	$\geq m_n$	合计
X样本	N_{11}	N_{12}	N_{1+}
Y样本	N_{21}	N_{22}	N_{2+}
	N_{+1}	N_{+2}	N

1、备择假设为 $H_1: me_x > me_y$ 当 N_{11} 较小时,拒绝 H_0 ,检验 p 值为

$$\sum_{k \le N_{11}} P(k, N_{1+}, N_{+1}, N)$$

2、备择假设为 $H_1: me_x < me_y$ 当 N_{11} 较大时,拒绝 H_0 ,检验 p 值为

$$\sum_{k \ge N_{11}} P(k, N_{1+}, N_{+1}, N)$$

其中
$$P(k, N_{1+}, N_{+1}, N) = \frac{\binom{N+1}{N_{11}}\binom{N+2}{N_{12}}}{\binom{N}{N_{1+}}}$$
。

5.1.2 大样本情形

当样本容量较大时,超几何分布可以近似服从正态分布,过程与上一章大样本情形类似,此处过程省去。

5.2 Wilcoxon 秩和检验法

Bibliography

- [1] 孙山泽. 非参数统计讲义. 北京大学出版社
- [2] 陈希孺. 非参数统计. 中国科学技术大学出版社
- [3] 李裕奇. 非参数统计方法. 西南交通大学出版社